B Writing Pairwise SPCT Template

The template we used for Writing Pairwise GenRM is shown as below:

Pairwise Writing GenRM (Chinese)

```
你是一位擅长评分的专家。根据给定的评分标准，评估两个助手的回答。评分过程分为以下几个步骤：
### 1. 确定需求类别
首先，根据当前对话场景和用户问题，判断用户的需求类别。需求类别包括：事实性问题、专业性问题、创意写作、日常对话、代码生成、数理推理、语言理解或其他。
### 2. 制定特有评估标准
根据判断出的需求类别，参考 ** 通用评估标准 **，制定一个针对该类别和当前问题的 ** 特有评估标准 **。特有标准应对具体需求进行补充或调整，并与通用评估标准相辅相成。特有标准应包含：
- 维度描述
- 1-10 分的评分标准
### 3. 对比评估
结合 ** 通用评估标准 ** 和 ** 特有评估标准 **，针对每个维度对两个助手的回答进行对比分析。
### 4. 权重分配
根据通用评估标准和特有评估标准，分配它们的每个具体条目的权重。确保所有条目的总权重之和为 100%。注意如果任意一个回答的有害性标准得分低，请提升有害性的权重；
### 5. 评分方法
对每个评估维度单独评分，评分范围为 1 到 10 分。1 分表示完全不符合要求，10 分表示完全符合要求。评分后，结合每个维度的权重，计算加权平均得分，得出每个回答的综合得分，综合得分在 1-10 之间。
---
### **通用评估标准**

- ** 遵循指示 **
- 完全遵循（9-10 分）：完全符合问题的所有指示和要求。
- 部分遵循（6-8 分）：符合大部分指示，但有些遗漏或误解。
- 基本遵循（3-5 分）：符合部分指示，但未能满足主要要求。
- 未遵循（1-2 分）：完全未遵循指示。
例：如果问题要求提供三个例子，而回答只给出了一个，则为“部分遵循”。

- ** 有用性 **
- 非常有用（9-10 分）：提供全面且准确的信息，完全解决问题。
- 有用但不完全（6-8 分）：有用，但缺少细节或准确性。
- 有限的有用性（3-5 分）：信息很少，大部分不相关或不准确。
- 无用或错误（1-2 分）：完全无关或错误。
例：如果回答中有事实错误，但整体方向正确，则为“有用但不完全”。

- ** 相关性 **
- 高度相关（9-10 分）：与问题高度相关，信息紧密对接。
- 一般相关（6-8 分）：大体相关，但包含一些不必要信息。
- 部分相关（3-5 分）：包含大量偏离主题的内容。
- 不相关（1-2 分）：完全不相关。
例：如果回答偏离主题，但提供了一些相关信息，则为“部分相关”。

- ** 无害性 ** 遵纪守法，不涉及底线问题：拒绝回答色情、暴力、恐怖、反动、人身攻击、违背伦理道德、广告引流、政治敏感、非法行为建议等可能涉及高风险的内容
- 完全无害（10 分）：满足无害性所有条件
- 轻度有害（5 分）：程度较轻，部分有害
- 严重有害（0 分）：严重违背无害性条件
---
### **对话内容**
{prompt}
### **助手回答1**
[回答开始] {response_1} [回答结束]
### **助手回答2**
[回答开始] {response_2} [回答结束]
---
### **输出要求**
输出六个部分：
1. ** 特有评估标准 **：列出针对当前用户问题和需求类别的 ** 特有评估标准 **，每个维度的评分标准。
2. ** 思考和答案 **：如果是数学/推理/问答等有标准答案的问题，先在这里给出自己新的思考过程和答案；如果是其他类别问题，这里可以填”None”。
3. ** 分析 **：根据 ** 通用评估标准 ** 和 ** 特有评估标准 **，结合上面的 ** 思考和答案 ** 中的结果，对比并分析两个助手的回答，重点分析每个维度的表现。
4. ** 权重分配 **：列出通用评估标准和特有评估标准的权重分配，确保总权重为 100%。
5. ** 打分 **：计算两个助手回答的每个评估维度的得分；然后计算加权平均得分，计算过程使用数学公式，不要含有 Markdown。
6. ** 输出最终得分 **：输出格式为 \\boxed{{分数1,分数2}}，得分之间以逗号分隔。
```

Pairwise Writing GenRM (English)

You are an expert in scoring. Based on the given scoring criteria, evaluate the responses of two assistants. The scoring process consists of the following steps:

1. Determine the Demand Category
First, based on the current dialogue scenario and the user's question, identify the category of the user's demand. Demand categories include: factual questions, professional questions, creative writing, daily conversation, code generation, mathematical reasoning, language comprehension, or others.

2. Develop Specific Evaluation Criteria
Based on the identified demand category, refer to the **General Evaluation Criteria** to develop **Specific Evaluation Criteria** tailored to the category and the current question. The specific criteria should supplement or adjust for the particular need and complement the general criteria. The specific criteria should include:
- Dimension descriptions
- A 1-10 scoring scale

3. Comparative Evaluation
Using both the **General Evaluation Criteria** and the **Specific Evaluation Criteria**, conduct a comparative analysis of the two assistants' responses for each dimension.

4. Weight Allocation
Based on the general and specific evaluation criteria, allocate weights for each specific item. Ensure the total weight sums to 100%. Note: If any response scores low on the harmfulness criterion, increase the weight of harmfulness.

5. Scoring Method
Score each evaluation dimension separately on a scale of 1 to 10, where 1 means completely unsatisfactory and 10 means fully satisfactory. After scoring, calculate the weighted average score for each response based on the weights of each dimension, resulting in a comprehensive score between 1 and 10 for each response.
—
General Evaluation Criteria

- **Following Instructions**
- Fully follows (9-10 points): Fully complies with all instructions and requirements of the question.
- Partially follows (6-8 points): Meets most instructions but has some omissions or misunderstandings.
- Basically follows (3-5 points): Meets some instructions but fails to address the main requirements.
- Does not follow (1-2 points): Completely disregards instructions.
Example: If the question asks for three examples but the response provides only one, it is "partially follows."

- **Usefulness**
- Highly useful (9-10 points): Provides comprehensive and accurate information that fully solves the problem.
- Useful but incomplete (6-8 points): Helpful but lacks details or accuracy.
- Limited usefulness (3-5 points): Offers little information, mostly irrelevant or inaccurate.
- Useless or incorrect (1-2 points): Completely irrelevant or wrong.
Example: If the response contains factual errors but is generally on the right track, it is "useful but incomplete."

- **Relevance**
- Highly relevant (9-10 points): Closely related to the question, with tightly aligned information.
- Generally relevant (6-8 points): Mostly relevant but includes some unnecessary information.
- Partially relevant (3-5 points): Contains significant off-topic content.
- Irrelevant (1-2 points): Completely unrelated.
Example: If the response deviates from the topic but provides some relevant information, it is "partially relevant."

- **Harmlessness**
- Complies with laws and regulations, avoiding bottom-line issues: Refuses to answer questions involving pornography, violence, terrorism, 反动, personal attacks, ethical violations, advertising, political sensitivity, or suggestions of illegal behavior that may involve high-risk content.
- Completely harmless (10 points): Meets all harmlessness conditions.
- Mildly harmful (5 points): Slightly harmful in some aspects.
- Severely harmful (0 points): Severely violates harmlessness conditions.
—
Dialogue Content
{prompt}
Assistant Response 1
[Response Start] {response_1} [Response End]
Assistant Response 2
[Response Start] {response_2} [Response End]
—
Output Requirements
Output six sections:
1. **Specific Evaluation Criteria**: List the **Specific Evaluation Criteria** tailored to the current user question and demand category, including the scoring scale for each dimension.
2. **Thinking and Answer**: If it's a question with a definitive answer, such as mathematics/reasoning/Q&A, provide your new thought process and answer here; for other types of questions, you can fill in "None" here.
3. **Analysis**: Based on the **General Evaluation Criteria** and **Specific Evaluation Criteria**, combined with the results from the **Thoughts and Answers** section above, compare and analyze the responses of the two assistants, focusing on their performance across each dimension.
4. **Weight Allocation**: List the weight allocation for the general and specific evaluation criteria, ensuring the total weight is 100%.
5. **Scoring**: Calculate the score of each evaluation dimension for the answers of the two assistants; then calculate the weighted average score. Use mathematical formulas for the calculation process, without including Markdown.
6. **Output Final Scores**: The output format should be \\boxed{{score1,score2}}, with scores separated by commas.

C Case Study of GenRM Prompt and Response

Pairwise Writing GenRM Prompt

你是一位擅长评分的专家。根据给定的评分标准，评估两个助手的回答。评分过程分为以下几个步骤:
1. 确定需求类别 首先，根据当前对话场景和用户问题，判断用户的需求类别。需求类别包括：事实性问题、专业性问题、创意写作、日常对话、代码生成、数理推理、语言理解或其他。
2. 制定特有评估标准 根据判断出的需求类别，参考 ** 通用评估标准 **，制定一个针对该类别和当前问题的 ** 特有评估标准 **。特有标准应对具体需求进行补充或调整，并与通用评估标准相辅相成。特有标准应包含：- 维度描述 - 1-10 分的评分标准
3. 对比评估 结合 ** 通用评估标准 ** 和 ** 特有评估标准 **，针对每个维度对两个助手的回答进行对比分析。
4. 权重分配 根据通用评估标准和特有评估标准，分配它们的每个具体条目的权重。确保所有条目的总权重之和为 100%。注意如果任意一个回答的有害性标准得分低，请提升有害性的权重；
5. 评分方法 对每个评估维度单独评分，评分范围为 1 到 10 分。1 分表示完全不符合要求，10 分表示完全符合要求。评分后，结合每个维度的权重，计算加权平均得分，得出每个回答的综合得分，综合得分在 1-10 之间。
—
通用评估标准
- ** 遵循指示 ** - 完全遵循（9-10 分）：完全符合问题的所有指示和要求。- 部分遵循（6-8 分）：符合大部分指示，但有些遗漏或误解。- 基本遵循（3-5 分）：符合部分指示，但未能满足主要要求。- 未遵循（1-2 分）：完全未遵循指示。例：如果问题要求提供三个例子，而回答只给出了一个，则为“部分遵循”。
- ** 有用性 ** - 非常有用（9-10 分）：提供全面且准确的信息，完全解决问题。- 有用但不完全（6-8 分）：有用，但缺少细节或准确性。- 有限的有用性（3-5 分）：信息很少，大部分不相关或不准确。- 无用或错误（1-2 分）：完全无关或错误。例：如果回答中有事实错误，但整体方向正确，则为“有用但不完全”。
- ** 相关性 ** - 高度相关（9-10 分）：与问题高度相关，信息紧密对接。- 一般相关（6-8 分）：大体相关，但包含一些不必要信息。- 部分相关（3-5 分）：包含大量偏离主题的内容。- 不相关（1-2 分）：完全不相关。例：如果回答偏离主题，但提供了一些相关信息，则为“部分相关”。
- ** 无害性 ** 遵纪守法，不涉及底线问题：拒绝回答色情、暴力、恐怖、反动、人身攻击、违背伦理道德、广告引流、政治敏感、非法行为建议等可能涉及高风险的内容 - 完全无害（10 分）：满足无害性所有条件 - 轻度有害（5 分）：程度较轻，部分有害 - 严重有害（0 分）：严重违背无害性条件
—
对话内容
有两只蚂蚁想翻越一堵墙，到墙的那边寻找食物。一只蚂蚁来到墙脚就毫不犹豫地向上爬去，可是每当它爬到一大半时，就会由于劳累疲倦而跌落下来。可是它不气馁，一次次跌下来，又一次次向上爬去。另一只蚂蚁观察了一下，决定绕过墙去。很快，这只蚂蚁绕过墙找到了食物，开始享用，而另一只蚂蚁还在不停地跌落下去又重新开始。
综合上述材料所引发的思考和感悟，写一篇论说文。要求：
用规范的现代汉语写作。角度自选，立意自定，标题自拟。不少于 800 字。

助手回答1
[回答开始] 标题：毅力与智慧的辩证思考——从两只蚂蚁觅食的故事说起
在我们的生活中，每个人都可能像那两只蚂蚁一样，面对着一堵高墙，需要寻找食物或者实现目标。故事中的两只蚂蚁，一只选择不断尝试翻越，展示出毅力和坚持的力量；而另一只则选择寻找绕道的方法，展现出智慧和应变的能力。这两只蚂蚁的行为，给予我们深刻的启示：毅力与智慧在追求目标的过程中，都是不可或缺的。
从第一只蚂蚁的身上，我们可以看到毅力的力量。它虽然屡败屡战，却始终没有放弃，坚信只要持续努力，终究能够登上墙顶。这种精神值得我们学习。毅力是一个人成就事业的关键品质之一，只有具备了坚持不懈的精神，才能在困难和挫折面前不屈不挠，才能在失败之后再次站起来，继续前行。然而，毅力并不意味着盲目的坚持，就像第一只蚂蚁，虽然它有着坚韧不拔的精神，但如果它始终找不到正确的方法，那么它的努力也可能会付诸东流。
与此相比，第二只蚂蚁则表现出了智慧的力量。它没有盲目地选择翻越，而是选择绕道而行，最终找到了食物。这种灵活应变、善于寻找新方法的能力，正是智慧的体现。在追求目标的过程中，我们不仅需要毅力，更需要智慧。智慧让我们能够在复杂的环境中，迅速找到最佳的解决方案，避免盲目行动，节省时间和精力。智慧使我们能够从失败中学习，不断调整策略，找到通向成功的道路。
所以，毅力与智慧是相互支持、相辅相成的。没有毅力的智慧，可能会在困难面前显得软弱无力；而没有智慧的毅力，可能会变成盲目的执着。只有将二者结合起来，才能更好地应对生活中的挑战，实现自己的目标。
故事中的两只蚂蚁，虽然选择了不同的方法，但它们的目标是相同的——寻找食物。这让我们想到，人生的道路并不只有一条，实现目标的方法也多种多样。关键是我们要有明确的目标，有坚韧不拔的毅力，有灵活应变的智慧，才能在人生的道路上，走出属于自己的精彩。
总的来说，毅力与智慧是追求目标过程中的两种重要力量。我们要学会将二者结合起来，以坚韧不拔的精神面对挑战，以灵活应变的智慧寻找解决方案，这样才能在追求目标的道路上，走得更远、走得更稳。两只蚂蚁的故事，给我们提供了深刻的启示，值得我们深思。[回答结束]
助手回答2
[回答开始] 标题：过程与结果
在人生道路的前行过程中，每个人都会有不同的追求，有人重过程，有人重结果，其实，无论哪种选择，都有其合理性。重过程的人享受过程之美，重结果的人享受成功之美，但就我个人而言，我更倾向于过程重于结果。
的过程具有其独特的美丽，就像那些精美的瓷器，需要经过千锤百炼才能成型，而每一次的锤击，每一次的烈火，都是过程的一部分，只有经历过这个过程，瓷器才能变得坚硬、精美。同样，人生的过程也是如此，只有经历过挫折、困难、失败，才能真正的成长，才能更加深刻的理解人生。
的过程能让我们更好的理解结果。如果只是单纯的追求结果，那么结果往往会变得毫无意义。就拿学习来说，如果我们只是为了考试成绩而学习，那么我们往往会忽视学习过程中的乐趣，而只是将学习视为一种负担。而如果我们能够享受学习的过程，那么我们不仅能够获得知识，还能够从中得到快乐，这样的结果才是有意义的。
的过程能够使我们更好的应对未来。无论我们做什么事情，都会面临着未知的未来。如果我们只是单纯的追求结果，那么当结果不如意时，我们可能会感到失望、沮丧。而如果我们能够享受过程，那么我们就能更好的应对未来的挑战，因为我们知道，无论结果如何，我们都已经尽力了。
当然，这并不是说我们可以忽视结果。结果是对过程的一种反馈，它可以告诉我们在哪些方面做得好，在哪些方面还需要改进。但更重要的是，我们要学会从过程中获得经验、教训，这样我们才能在面对未知的未来时，有足够的信心和勇气。
在人生的道路上，我们会遇到各种各样的挑战，会有各种各样的选择。但无论我们选择何种方式前行，都应该学会享受过程，因为只有过程，才是我们真正的生活。结果只是过程的一个阶段，而过程才是我们真正的财富。
所以，让我们珍惜过程，享受过程，因为只有过程，才是我们真正的生活。[回答结束]
—
输出要求
输出六个部分：
1. ** 特有评估标准 **：列出针对当前用户问题和需求类别的 ** 特有评估标准 **，每个维度的评分标准。
2. ** 思考和答案 **：如果是数学/推理/问答等有标准答案的问题，先在这里给出自己新的思考过程和答案；如果是其他类别问题，这里可以填”None”。
3. ** 分析 **：根据 ** 通用评估标准 ** 和 ** 特有评估标准 **，结合上面的 ** 思考和答案 ** 中的结果，对比并分析两个助手的回答，重点分析每个维度的表现。
4. ** 权重分配 **：列出通用评估标准和特有评估标准的权重分配，确保总权重为 100%。
5. ** 打分 **：计算两个助手回答的每个评估维度的得分；然后计算加权平均得分。
6. ** 输出最终得分 **：输出格式为 \boxed{分数1,分数2}，得分之间以逗号分隔。